Аналізуємо події за допомогою Riak, Pipes та Foldl

Kostiantyn Rybnikov

November 26, 2016

Огляд проблеми, яку вирішуємо

- Порахувати від 1 до 1000 не так-то й просто
- Система записує складні структуровані дані у великій кількості
- Їх потрібно аналізувати, генеруючи деякий результат, візуалізацію

Мотивація, більшість існуючих систем

- Слабка або відсутність типізації
- Не на Хаскелі
- Важко писати та підтримувати map/reduce
- Важко тестувати
- Відсутність композиції

"Beautiful folds" (Красиві згортачі?)

- Beautiful folding (Max Rabkin, 2008)
- Composable streaming folds (Gabriel Gonzalez, 2013)
- foldl-1.0.0: Composable, streaming, and efficient left folds (Gabriel Gonzalez, 2013)
- Популяризовано Scala-бібліотекою algebird, див MuniHac 2016: Beautiful folds are practical, too

Beautiful folds – проблема

```
:{
Prelude Data.List Data.List| sum :: (Num a) => [a] -> a
Prelude Data.List Data.List| sum = foldl' (+) 0
Prelude Data.List Data.List| :}
>>> genericLength [1..100000000]
100000000
>>> sum [1..100000000]
500000050000000
>>> let average xs = sum xs / genericLength xs
>>> average [1..100000000]

'Huge space leak>
```

Beautiful folds – наївне вирішення

Еволюція

```
foldl' :: (a -> b -> a) -> a -> [b] -> a

data Fold b c = forall a. F (a -> b -> a) a (a -> c)

data Fold b a = F (a -> b -> a) a

data Fold i o = forall m . Monoid m => Fold (i -> m) (m -> o)
```

Beautiful folds в один слайд

```
Імплементація в 14 строк Хаскеля:
{-# LANGUAGE ExistentialQuantification #-}
{-# LANGUAGE RankNTypes
                                        #-}
import Control.Lens (Getting, foldMapOf)
data Fold i o = forall m . Monoid m => Fold (i -> m) (m -> o)
instance Functor (Fold i) where
    fmap k (Fold tally summarize) = Fold tally (k . summarize)
instance Applicative (Fold i) where
    pure o = Fold (\ -> \ ()) \ (\ -> \ o)
    Fold tallyF summarizeF <*> Fold tallyX summarizeX = Fold tally summarize
      where
        tally i = (tallyF i, tallyX i)
        summarize (mF, mX) = summarizeF mF (summarizeX mX)
focus :: (forall m . Monoid m => Getting m b a) -> Fold a o -> Fold b o
focus lens (Fold tally summarize) = Fold (foldMapOf lens tally) summarize
```

Простий приклад

```
{-# LANGUAGE ExistentialQuantification #-}
import Data.Monoid
import Prelude hiding (sum)

import qualified Data.Foldable

data Fold i o = forall m . Monoid m => Fold (i -> m) (m -> o)

fold :: Fold i o -> [i] -> o
fold (Fold tally summarize) is = summarize (reduce (map tally is))
   where
    reduce = Data.Foldable.foldl' (<>) mempty

sum :: Num n => Fold n n
sum = Fold Sum getSum
```

Простий приклад

Як це працює?

```
print (fold sum [1, 2, 3, 4])
-- sum = Fold Sum getSum
= print (fold (Fold Sum getSum) [1, 2, 3, 4])
-- fold (Fold tally summarize) is = summarize (reduce (map tally is))
= print (getSum (reduce (map Sum [1, 2, 3, 4])))
-- reduce = foldl' (<>) mempty
= print (getSum (foldl' (<>) mempty (map Sum [1, 2, 3, 4])))
-- Definition of `map` (skipping a few steps)
= print (getSum (foldl' (<>) mempty [Sum 1, Sum 2, Sum 3, Sum 4]))
-- `foldl' (<>) mempty` (skipping a few steps)
= print (getSum (mempty <> Sum 1 <> Sum 2 <> Sum 3 <> Sum 4))
-- mempty = Sum 0
= print (getSum (Sum 0 <> Sum 1 <> Sum 2 <> Sum 3 <> Sum 4))
-- Sum x \iff Sum y = Sum (x + y)
= print (getSum (Sum 10))
-- getSum (Sum x) = x
= print 10
```

Більш цікавий приклад

```
{-# LANGUAGE BangPatterns #-}

data Average a = Average { numerator :: !a, denominator :: !Int }

instance Num a => Monoid (Average a) where
    mempty = Average 0 0
    mappend (Average xL nL) (Average xR nR) = Average (xL + xR) (nL + nR)

-- Not a numerically stable average, but humor me
average :: Fractional a => Fold a a
average = Fold tally summarize
where
    tally x = Average x 1

summarize (Average numerator denominator) =
    numerator / fromIntegral denominator
```

Приклад

Немає витоку простору!

Наша average працює за константну пам'ять:

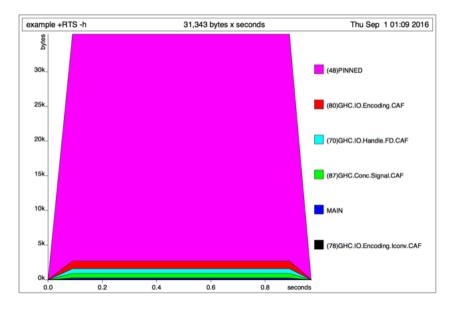


Figure 1:

Як це працює?

```
print (fold average [1, 2, 3])
-- average = Fold tally summarize
= print (fold (Fold tally summarize ) [1, 2, 3])
-- fold (Fold tally summarize) is = summarize (reduce (map tally is))
= print (summarize (reduce (map tally [1, 2, 3])))
-- reduce = foldl' (<>) mempty
= print (summarize (foldl' (<>) mempty (map tally [1, 2, 3])))
-- Definition of `map` (skipping a few steps)
= print (summarize (foldl' (<>) mempty [tally 1, tally 2, tally 3]))
-- tally x = Average x 1
= print (summarize (mconcat [Average 1 1, Average 2 1, Average 3 1]))
-- `foldl' (<>) mempty` (skipping a few steps)
= print (summarize (mempty <> Average 1 1 <> Average 2 1 <> Average 3 1))
-- mempty = Average 0 0
= print (summarize (Average 0 0 <> Average 1 1 <> Average 2 1 <> Average 3 1))
-- Average xL nL <> Average xR nR = Average (xL + xR) (nL + nR)
= print (summarize (Average 6 3))
-- summarize (Average numerator denominator) = numerator / fromIntegral denominator
= print (6 / fromIntegral 3)
```

Прості Foldи

```
Все в Data. Monoid можна загорнути в Fold
import Prelude hiding (head, last, all, any, sum, product, length)
head :: Fold a (Maybe a)
head = Fold (First . Just) getFirst
last :: Fold a (Maybe a)
last = Fold (Last . Just) getLast
all :: (a -> Bool) -> Fold a Bool
all predicate = Fold (All . predicate) getAll
any :: (a -> Bool) -> Fold a Bool
any predicate = Fold (Any . predicate) getAny
sum :: Num n => Fold n n
sum = Fold Sum getSum
product :: Num n => Fold n n
product = Fold Product getProduct
length :: Num n => Fold i n
length = Fold (\_ -> Sum 1) getSum
```

Приклади

```
>>> fold head [1..10]
Just 1
>>> fold last [1..10]
Just 10
>>> fold (all even) [1..10]
False
>>> fold (any even) [1..10]
True
>>> fold sum [1..10]
55
>>> fold product [1..10]
3628800
>>> fold length [1..10]
10
```

Експоненційне ковзне середнє

```
Експоненційне ковзне середнє у вигляді Foldy:
data EMA a = EMA { samples :: !Int, value :: !a }
instance Fractional a => Monoid (EMA a) where
    mempty = EMA \circ \circ
    mappend (EMA nL xL) (EMA 1 xR) = EMA n x -- Optimize common case
      where
        n = nL + 1
        x = xL * 0.7 + xR
    mappend (EMA nL xL) (EMA nR xR) = EMA n x
      where
        n = nL + nR
        x = xL * (0.7 ^nR) + xR
ema :: Fractional a => Fold a a
ema = Fold tally summarize
  where
    tally x = EMA 1 x
    summarize (EMA _{\rm x}) = x * 0.3
```

Приклад

Оцінка кардинальності

... погано для великих даних

```
Типове питання, що виникає — "оцінити кількість унікальних відвідувачів"

Наївне рішення:

import Data.Set (Set)

import qualified Data.Set

uniques :: Ord i => Fold i Int

uniques = Fold Data.Set.singleton Data.Set.size

... потребує багато пам'яті
```

Приблизна оцінка кардинальності

```
Алгоритм HyperLogLog дає приблизну оцінку кардинальності
Спрощене пояснення на Хаскелі:
import Data.Word (Word64)
import qualified Data.Bits
newtype Max a = Max { getMax :: a }
instance (Bounded a, Ord a) => Monoid (Max a) where
    mempty = Max minBound
    mappend (Max x) (Max y) = Max (max x y)
uniques :: (i -> Word64) -> Fold i Int
uniques hash = Fold tally summarize
  where
    tally x = Max (fromIntegral (Data.Bits.countLeadingZeros (hash x)) :: Word64)
    summarize (Max n) = fromIntegral (2 ^ n)
Справжня версія набагато більш "дужа" (Див hyperloglog від E. Kmett)
```

Приклад

Код, що варто вкрасти

Деякі ідеї, що вкрадено зі Скала-бібліотеки algebird

- Quantile digests (for medians, percentiles, histograms)
 - algebird calls these QTrees
- Count-min sketch (for top N most frequently occurring items)
 - algebird generalizes this as SketchMaps
- Stochastic gradient descent (for linear regression)
 - algebird calls this SGD
- Bloom filters (for approximate membership testing)
 - algebird calls this BF

algebird's version of Fold is called ${\tt Aggregator}$

Комбінуємо Foldи

Уявімо, що ми хочемо зкомбінувати два Foldu в один

```
Ми би зробили щось типу:
```

```
combine :: Fold i a -> Fold i b -> Fold i (a, b)
combine (Fold tallyL summarizeL) (Fold tallyR summarizeR) = Fold tally summarize
  where
  tally x = (tallyL x, tallyR x)
summarize (sL, sR) = (summarizeL sL, summarizeR sR)
```

Приклад

```
>>> fold (combine sum product) [1..10] (55,3628800)
```

Applicative

```
Moжемо узагальнити combine написавши iнстанс Fold для Applicative

instance Functor (Fold i) where
fmap k (Fold tally summarize) = Fold tally (k . summarize)

instance Applicative (Fold i) where
pure o = Fold (\_ -> ()) (\_ -> o)

Fold tallyF summarizeF <*> Fold tallyX summarizeX = Fold tally summarize
where
tally i = (tallyF i, tallyX i)

summarize (mF, mX) = summarizeF mF (summarizeX mX)
```

Строгість

```
Ми хочемо, аби внутрішній Monoid був строгим Pair:
data Pair a b = P !a !b
instance (Monoid a, Monoid b) => Monoid (Pair a b) where
    mempty = P mempty mempty
    mappend (P aL bL) (P aR bR) = P (mappend aL aR) (mappend bL bR)
data Fold i o = forall m . Monoid m => Fold (i -> m) (m -> o)
instance Functor (Fold i) where
    fmap k (Fold tally summarize) = Fold tally (k . summarize)
instance Applicative (Fold i) where
    pure o = Fold (\_ -> ()) (\_ -> o)
    Fold tallyF summarizeF <*> Fold tallyX summarizeX = Fold tally summarize
      where
        tally i = P (tallyF i) (tallyX i)
        summarize (P mF mX) = summarizeF mF (summarizeX mX)
Це дозволить використовувати seq замість deepseq
```

Pairing values

```
Tenep ми можемо написати:

combine :: Fold i a -> Fold i b -> Fold i (a, b)

combine = liftA2 (,)

... що має більш узагальнений тип:

combine :: Applicative f => f a -> f b -> f (a, b)

Альтернативно, можемо використовувати Applicative напряму:

>>> fold ((,) <$> sum <*> product) [1..10]

(55,3628800)
```

Анти-паттерн

```
Порівняйте дві функції:
```

```
bad :: [Double] -> (Double, Double)
bad xs = (Prelude.sum xs, Prelude.product xs)
good :: [Double] -> (Double, Double)
good xs = fold ((,) <$> sum <*> product) xs
Яка проблема в першої з них?
```

Застосовуємо Applicativeи

0m0.006s

sys

Можемо використовувати Applicative-інстанси не тільки для пар: sum :: Num n => Fold n nsum = Fold Sum getSum length :: Num n => Fold i n length = Fold (_ -> Sum 1) getSum average :: Fractional n => Fold n n average = (/) <\$> sum <*> length Генерує код, еквівалентний average, написаному "вручну": main :: IO () main = print (fold average (map fromIntegral [(1::Int)..1000000000])) \$ time ./example # 1.3 ns / elem 5.00000000067109e8 0m1.281s real 0m1.266s user

Num

```
Можемо надати інстанси Fold класам Num, Fractional та Floating!
instance Num b => Num (Fold a b) where
    fromInteger n = pure (fromInteger n)
    negate = fmap negate
           = fmap abs
    abs
    signum = fmap signum
    (+) = liftA2 (+)
    (*) = liftA2 (*)
    (-) = liftA2 (-)
instance Fractional b => Fractional (Fold a b) where
    fromRational n = pure (fromRational n)
    recip = fmap recip
    (/) = liftA2 (/)
instance Floating b => Floating (Fold a b) where
    pi = pure pi
         = fmap exp
    exp
    sqrt = fmap sqrt
         = fmap log
    log
         = fmap sin
    sin
         = fmap tan
    tan
          = fmap cos
    cos
    asin = fmap sin
    atan = fmap atan
    acos = fmap acos
    sinh = fmap sinh
    tanh = fmap tanh
    cosh = fmap cosh
    asinh = fmap asinh
    atanh = fmap atanh
    acosh = fmap acosh
```

(**) = liftA2 (**)
logBase = liftA2 logBase

Числові Foldи

Можемо робити круті штуки:

```
>>> fold (length - 1) [1..10]
9
>>> let average = sum / length
>>> fold average [1..10]
5.5
>>> fold (sin average ^ 2 + cos average ^ 2) [1..10]
1.0
>>> fold 99 [1..10]
99
```

Стандартне відхилення

Формула стандартного відхилення:

$$\sqrt{\frac{1}{N} \sum_{i=1}^{N} (x_i - \overline{x})^2} = \sqrt{\frac{1}{N} \left(\sum_{i=1}^{N} x_i^2\right) - \overline{x}^2} = \sqrt{\left(\frac{1}{N} \sum_{i=1}^{N} x_i^2\right) - \left(\frac{1}{N} \sum_{i=1}^{N} x_i\right)^2}$$

Еквівалент через Fold читається майже так само просто, як остання формула:

```
standardDeviation :: Floating n => Fold n n
standardDeviation = sqrt ((sumOfSquares / length) - (sum / length) ^ 2)
  where
    sumOfSquares = Fold (Sum . (^2)) getSum
>>> fold standardDeviation [1..100]
28.86607004772212
```

Фолдимо ListT

```
ListT із пакету list-transformers визначено так:
newtype ListT m a = ListT { next :: m (Step m a) }
data Step m a = Cons a (ListT m a) | Nil
Можемо його згорнути!
{-# LANGUAGE BangPatterns #-}
import List.Transformer (ListT(..), Step(..))
import qualified System.IO
foldListT :: Monad m => Fold i o -> ListT m i -> m o
foldListT (Fold tally summarize) = go mempty
  where
    go !m l = do
        s <- next l
        case s of
                      -> return (summarize m)
            Nil
            Cons x 1' \rightarrow go (mappend m (tally x)) 1'
```

Приклад

Можемо таким чином згорнути "effectful streams":

```
stdin :: ListT IO String
stdin = ListT (do
    eof <- System.IO.isEOF
    if eof
        then return Nil
        else do
            line <- getLine
            return (Cons line stdin) )

main :: IO ()
main = do
    n <- foldListT length stdin
    print n

$ yes | head -100000000 | ./example
100000000</pre>
```

Згортаємо потокові бібліотеки

Можемо таким самим чином згорнути:

- conduit
- io-streams
- list-t
- logict
- machines
- pipes
- turtle

Кожен Fold може бути перевикористаним в будь-якій із цих систем

Лінзи

```
{-# LANGUAGE RankNTypes #-}
import Control.Lens (Getting, foldMapOf)

focus :: (forall m . Monoid m => Getting m b a) -> Fold a o -> Fold b o
focus lens (Fold tally summarize) = Fold tally' summarize
   where
    tally' = foldMapOf lens tally

focus _1 :: Fold i o -> Fold (i, x) o

focus _Just :: Fold i o -> Fold (Maybe i) o
```

Приклад

```
items1 :: [Either Int String]
items1 = [Left 1, Right "Hey", Right "Foo", Left 4, Left 10]
>>> fold (focus _Left sum) items1
15
>>> fold (focus _Right length) items1
2
items2 :: [Maybe (Int, String)]
items2 = [Nothing, Just (1, "Foo"), Just (2, "Bar"), Nothing, Just (5, "Baz")]
>>> fold (focus (_Just . _1) product) items2
10
>>> fold (focus _Nothing length) items2
2
```

На (нашій) практиці

- Великі структури даних івентів
- Декілька джерел
- Великі структури даних звітів
- Більшість результатів "в часі"
- Багато обв'язки для збереження та завантаження

Івенти

```
data DsAdBid a = DsAdBid
    { _abImpressionId :: ImpressionId
    , _abDelay
                    :: Maybe PageLoadDelay
    , _abDsAccountId :: DsAccountId
    , _abAdregionId :: AdregionId
    , _abBid
                    :: Bid
    , _abCreativeCore :: Maybe Cr.CreativeCore
    deriving (Show, Eq, Generic)
data CreativeCore
  = CreativeCore
     { _coreTitle
                   :: Maybe Title
     , _coreDescription :: Maybe Description
      , _coreSponsor :: Maybe Sponsor
     , _coreImgURL
                    :: Maybe (Valid RawURL)
  deriving (Eq, Generic, Show)
```

Folds.hs

Простий випадок

Складніше

```
• помітьте, як ми передаємо мапу в пам'яті замість джойнів
   | SELECT GROUPKEY(ds id, adregion id, round5min(timestamp)),
            count(ds ad load events)
            earnings(ds ad load events)
            count(ds click events)
     FROM ds_ad_load_events, ds_click_events
processCountLoadsAndClicksAndEarningsConcurrent :: Mode -> IO ()
processCountLoadsAndClicksAndEarningsConcurrent mode = void . runConsumerInMode mode $ do
    (KeyFunction kf) <- getKeyFunctionDsAdregion
    let (EvProducer prod) = evProducerW start end
    ((lc,le),cc) <- concurrently2
        (purelyFold ((,) <$> countFold kf <*> earningsFold kf)
                    (prod :: EventProducer (Event DsAdLoad)))
        (purelyFold (countFold kf)
                    (prod :: EventProducer (Event DsClick)))
    liftIO (print (mhmZip3 lc le cc))
    -- :: MonoidalHashMap KeyDsAdregion (Sum Integer, Sum MoneyAmount,
                                          Sum Integer)
type KeyAdregionDs = (AdregionId, DsProviderId, UTCTime)
getKeyFunctionDsAdregion :: Consumer (KeyFunction KeyAdregionDs)
keyFunctionAdregionDs :: KeyConstraints KeyAdregionDs ev
                      => HashMap DsAccountId DsProviderId
                      -> (ev -> Maybe KeyAdregionDs)
keyFunctionAdregionDs dsMap event = do
    let accountID = event ^. dsAccountId
    dsID
                <- H.lookup accountID dsMap
    let region
                  = event ^. adregionId
    let timekey = rewindTo5Min (event ^. timestamp)
    return (region, dsID, timekey)
```

Складніші репорти

Foldu для складніших репортів

```
processStats = do
  aggs <- aggregateEventStreams dsMap (evProducer</pre>
                                                   startTime endTime
                                   :: EventProducer (Event DsAdLoad))
                                                startTime endTime
                                  (evProducer
                                   :: EventProducer (Event DsImpression))
                                  (evProducer startTime endTime
                                   :: EventProducer (Event DsClick))
                                  (evProducer startTime endTime
                                   :: EventProducer (Event DsAvailabilityCheck))
                                  (evProducer startTime endTime
                                   :: EventProducer (Event DsAdAvail))
                                  (evProducer startTime endTime
                                   :: EventProducer (Event DsAdUnavail))
                                  (evProducer startTime endTime
                                   :: EventProducer (Event DsAdError))
                                  (evProducer startTime endTime
                                   :: EventProducer (Event DsCookieSync))
  where
```

... продовження ...

Візуалізація

• GHCJS + Reflex

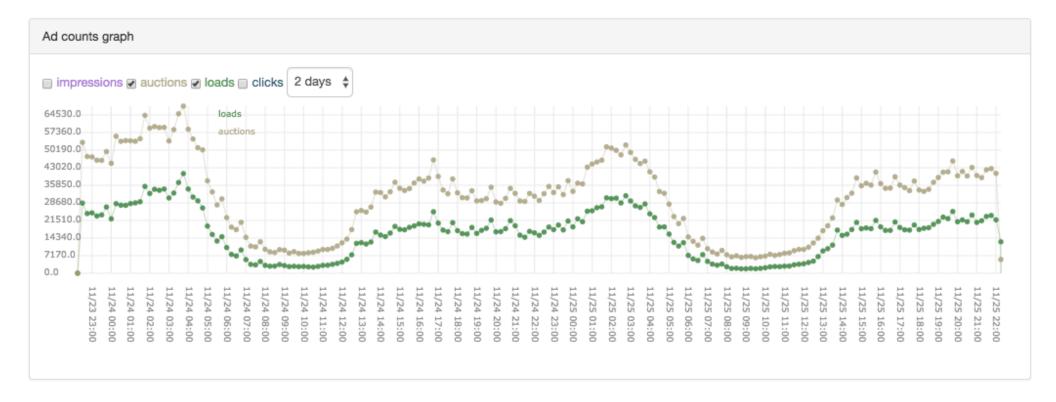


Figure 2: dashboard

Чого не вистачає

- Швидкість (data locality, нерівномірність бакетів)
- Компактне збереження результатів (абстракція розділення по інтервалах та збереження)
- REPL або блокнотик
- GUI для репроцессингу
- Real-time in-memory analytics